Data Preprocessing Bagian - I

27 Maret 2024

Tujuan Materi Hari Ini

1. Memahami langkah-langkah dasar dalam melakukan *data preprocessing* yang dilakukan diantara proses *importing data* dan *data cleansing*, serta pentingnya *preprocess* dalam proyek *machine learning*

2. Menangani *missing values*, *data encoding*, *scaling,* dan *splitting*

3. Mendapatkan pengalaman praktis melalui contoh dan latihan.

Apa itu *Data Preprocessing*?

- Dilakukan setelah *Exploratory Data Analysis* (EDA) dan *data cleaning*
- Mempersiapkan data untuk pemodelan
- **Contoh:** mentransformasi fitur kategorik menjadi fitur numerik (*dummy variable*)

Mengapa *Preprocess* Dilakukan?

- Mengubah data menjadi sesuai untuk dimodelkan
- Meningkatkan performa model
- Memberikan hasil yang *reliable*

Penanganan Data yang Hilang (Missing Values)

Mengapa dan Bagaimana

Mengapa Ada Missing Values ?

- Faktanya, data di dunia nyata seringkali ditemukan dalam bentuk yang tidak rapi/kacau/berantakan/tidak teratur
    - **“Did you know that 72% of organizations believe that data quality issues hinder customer trust and perception?”** (*)

*[Top 9 Benefits of Data Cleansing for Businesses](https://bit.ly/2QwMrab)

Mengapa Ada Missing Values ?

- ***Values* yang hilang dalam proses akuisisi data**
  - Sensor cuaca rusak selama analisis cuaca
  - Informasi pasien yang tidak lengkap untuk diagnosis medis dll.

- ***Values* terhapus secara tidak sengaja**
  - Data yang hilang
  - Tidak sengaja terhapus akibat *human error*

Workflow Penanganan Missing Values

1. Ubah semua missing values menjadi “null” values.
2. Menganalisis jumlah dan jenis data dari missing values.
3. Delete atau impute missing values dengan cara yang tepat.
4. Evaluasi & bandingkan performa dari data yang telah ditangani/imputasi tadi saat di-inputkan pada model

Wujud Missing Values Pada Dataset

- Biasanya berupa dengan nilai seperti berikut:
  - `'NA'`,
  - `'-'`
  - `'.'`
  - `'0'`
  - ... dll

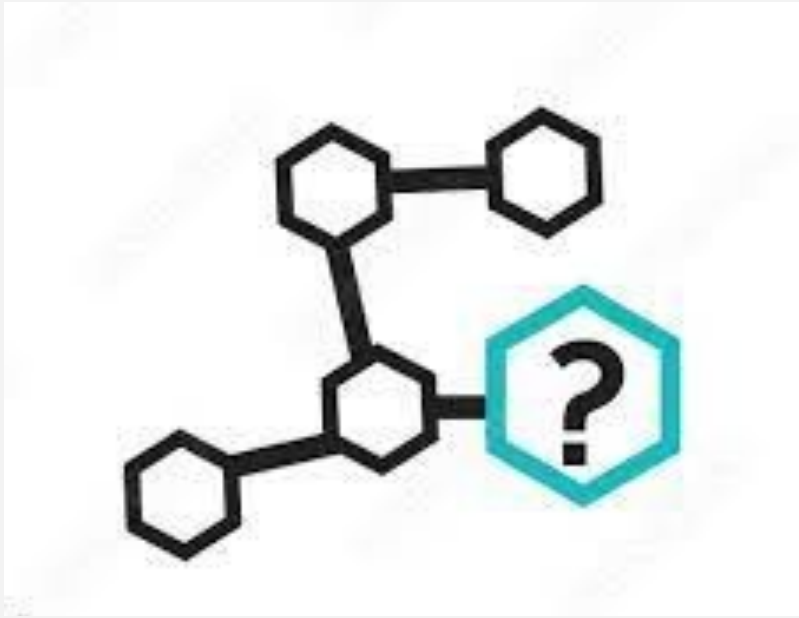

Implementasi

- Hands-on Coding in Google Colab
  - Dataset Cases:
    - college.csv
    - pima-indian-diabetes.csv

Apa itu Data Imputation?

- Proses mengisi atau menggantikan nilai yang hilang atau tidak lengkap dalam sebuah dataset
- Bertujuan untuk mempertahankan integritas dan kualitas dataset
- Menghindari kehilangan informasi yang berpotensi penting

Imputasi: Teknik Dasar

- Konstan (contoh: `'0'`)
- Rata-rata (mean)
- Nilai Tengah (Median)
- Modus (mode or most frequent)

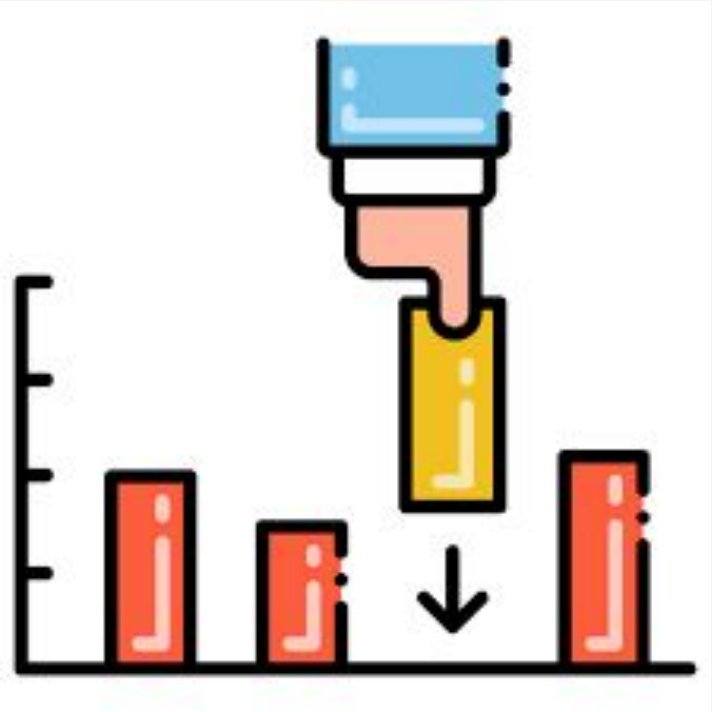

Implementasi & Visualisasi

- Hands-on Coding in Google Colab

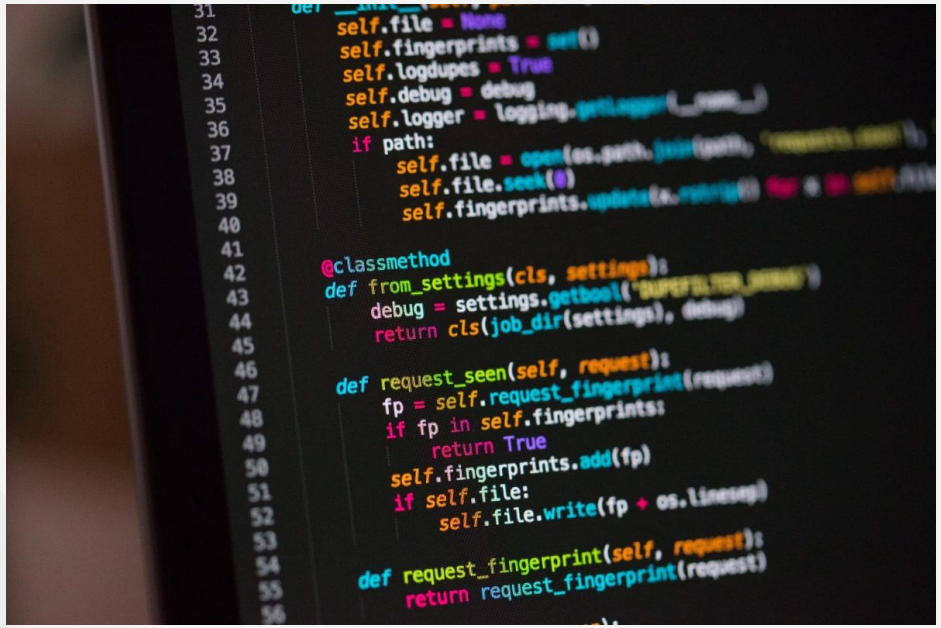

Label Encoder

dan Penerapannya

Implementasi

- Hands-on Coding in Google Colab

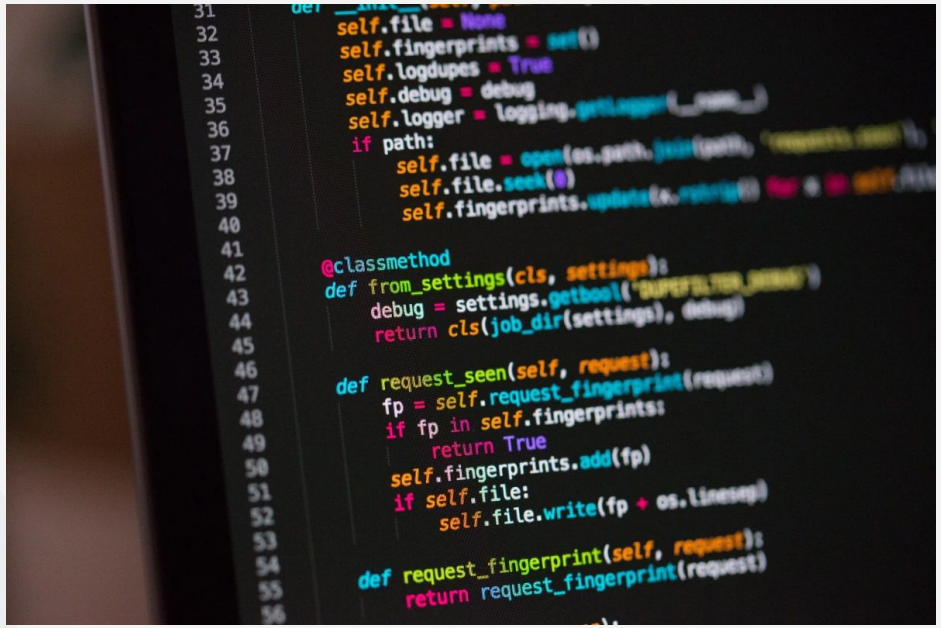

One-Hot Encoding

dan Penerapannya

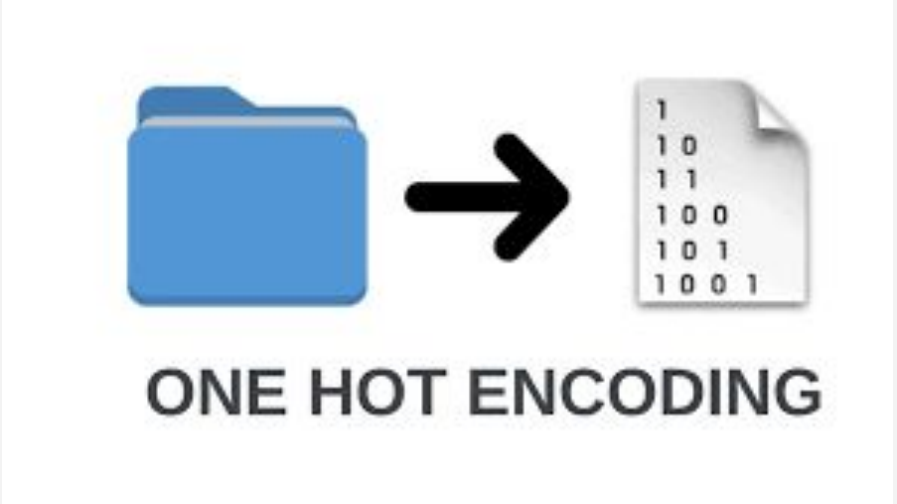

One-Hot Encoding

fav_color
blue
green
orange
green

fav_color_enc
[1, 0, 0]
[0, 1, 0]
[0, 0, 1]
[0, 1, 0]

Values: [blue, green, orange]

- blue : [1, 0, 0]
- green : [0, 1, 0]
- orange : [0, 0, 1]

Implementasi

- Hands-on Coding in Google Colab

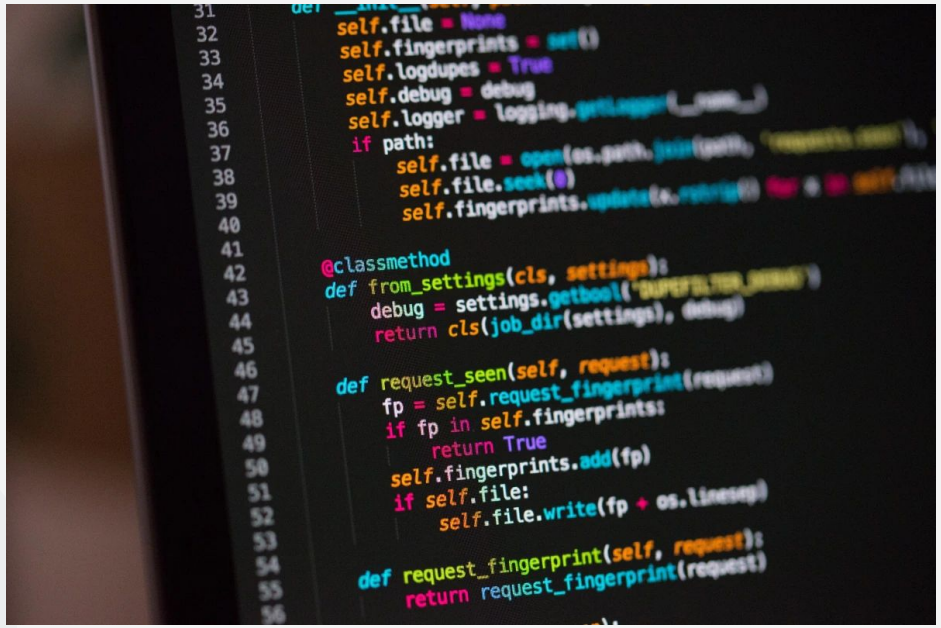

Standarisasi

Apa dan Kapan serta Implementasinya

Apa itu Standarisasi?

Definisi: mengubah data kontinu agar menyerupai distribusi normal

- Model-model pada library "*scikit-learn*" mengasumsikan data yang diinputkan terdistribusi secara normal

- Menggunakan *data training* yang tidak terdistribusi secara normal dapat mengakibatkan error (*bias*)

- ***Log normalization*** dan ***feature scaling*** yang akan kita terapkan
  Diterapkan pada data yang bersifat numerik kontinu

Kapan Harus Lakukan Standarisasi?

1. **Model pada ruang linier (*linear space*)**

Contoh:

- k-Nearest Neighbors (kNN)
- Linear regression
- K-Means Clustering

2. **Dataset yang memiliki fitur-fitur bersifat *high variance***

   Hal ini dapat membiaskan model yang mengasumsikan data terdistribusi secara normal.

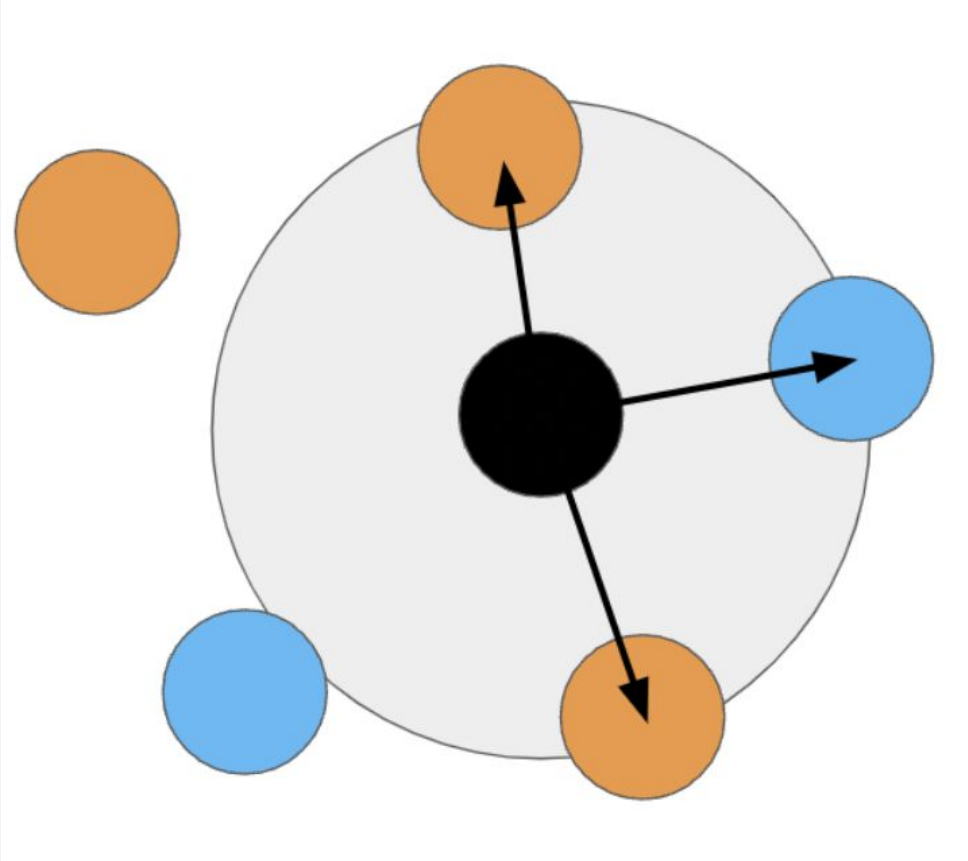

Kapan Harus Lakukan Standarisasi?

3. **Fitur-fitur yang memiliki skala yang berbeda satu sama lainnya.**

4. **Asumsi Linearitas**

   Standarisasi membantu memastikan bahwa asumsi linearitas terpenuhi dan meningkatkan kinerja model machine learning, terutama pada algoritma yang bergantung pada hubungan linear antara variabel independen dan dependen.

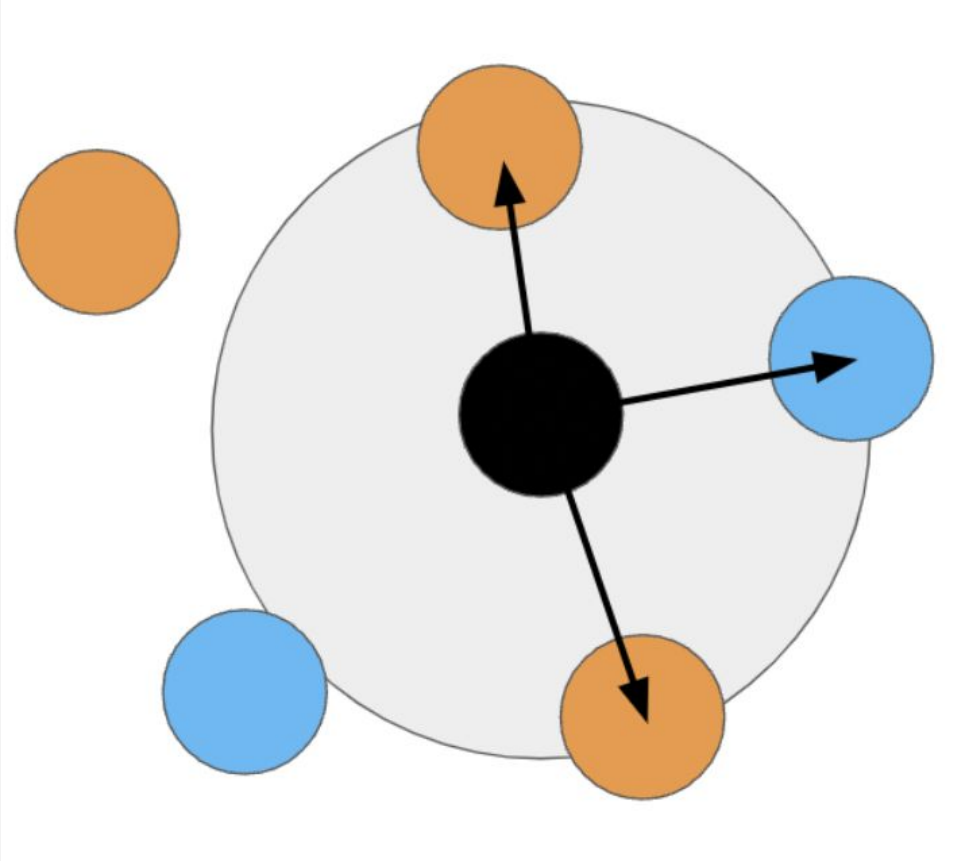

Apa itu *log normalization*?

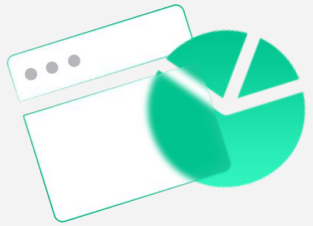

- Berguna untuk fitur dengan variasi tinggi
- Menerapkan transformasi logaritma
- Log natural menggunakan konstanta e (≈ 2.718)
- $e^{3.4} = 30$
- Menangkap perubahan relatif, besarnya perubahan, dan menjaga semuanya tetap positif

Number	Log
30	3.4
300	5.7
3000	8

Log Normalization in Python

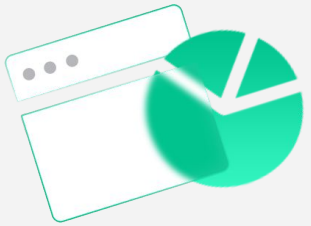

```
print(df)
```

```
   col1   col2
0  1.00    3.0
1  1.20   45.5
2  0.75   28.0
3  1.60  100.0
```

```
print(df.var())
```

```
col1       0.128958
col2    1691.729167
dtype: float64
```

```
import numpy as np
df["log_2"] = np.log(df["col2"])
print(df)
```

```
   col1   col2     log_2
0  1.00    3.0  1.098612
1  1.20   45.5  3.817712
2  0.75   28.0  3.332205
3  1.60  100.0  4.605170
```

```
print(df[["col1", "log_2"]].var())
```

```
col1     0.128958
log_2    2.262886
dtype: float64
```

Apa itu *feature scaling*?

- Fitur-fitur pada skala yang berbeda
- Model dengan karakteristik linier
- Memusatkan nilai fitur di sekitar `0` dan mengubah menjadi ber-varians `1`
- Mentransformasi agar mendekati distribusi normal

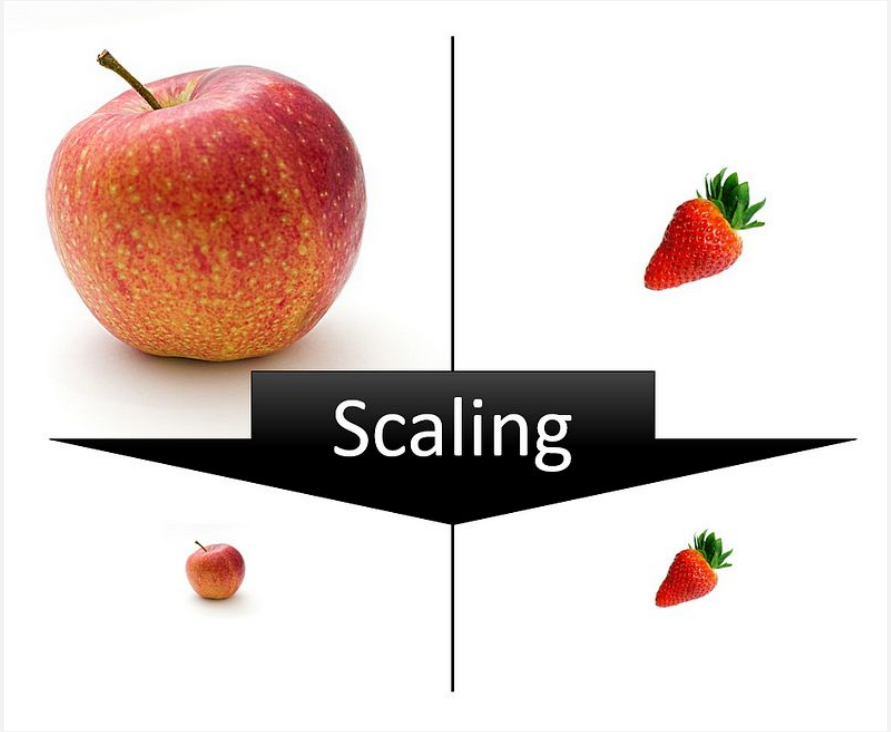

Bagaimana menskalakan data?

```
print(df)
```

```
   col1  col2   col3
0  1.00  48.0  100.0
1  1.20  45.5  101.3
2  0.75  46.2  103.5
3  1.60  50.0  104.0
```

```
print(df.var())
```

```
col1    0.128958
col2    4.055833
col3    3.526667
dtype: float64
```

Bagaimana menskalakan data?

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
df_scaled = pd.DataFrame(scaler.fit_transform(df),
                         columns=df.columns)
```

```
print(df_scaled)
```

```
       col1      col2      col3
0 -0.442127  0.329683 -1.352726
1  0.200967 -1.103723 -0.553388
2 -1.245995 -0.702369  0.799338
3  1.487156  1.476409  1.106776
```

```
print(df_scaled.var())
```

```
col1    1.333333
col2    1.333333
col3    1.333333
dtype: float64
```

Train-Test Split Dataset

Apa dan Kenapa

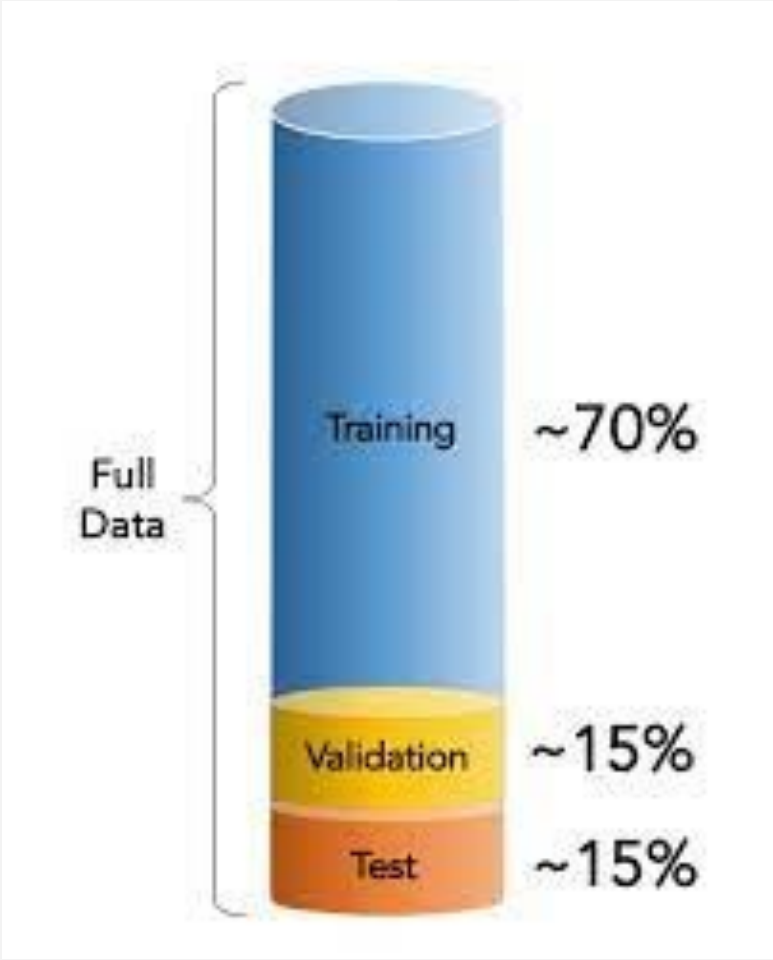

Apa itu Train-Test Splitting?

- Train-Test Splitting adalah salah satu teknik yang umum digunakan dalam *machine learning* untuk menguji kinerja model pada data yang belum pernah dilihat sebelumnya

- Bertujuan untuk memisahkan dataset menjadi train set dan subset pengujian test set.

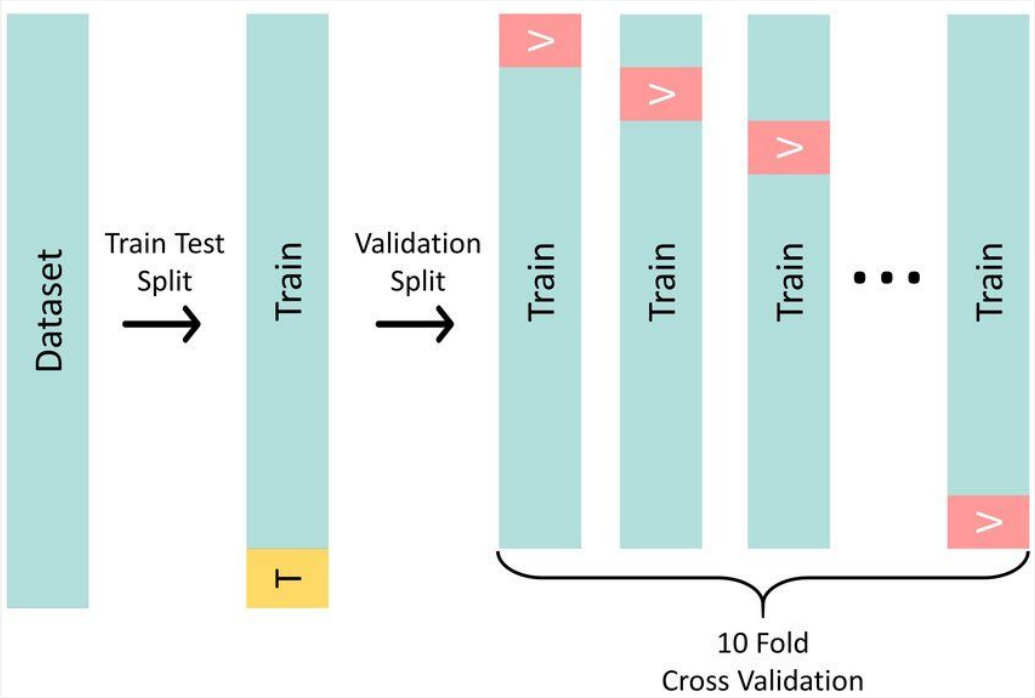

Manfaat Train-Test Splitting

- Mengukur kinerja model secara objektif
- Mencegah overfitting
- Generalisasi ML Model
- Mendeteksi masalah dan debugging
- Pemilihan model yang lebih baik

Implementasi

- Hands-on Coding in Google Colab

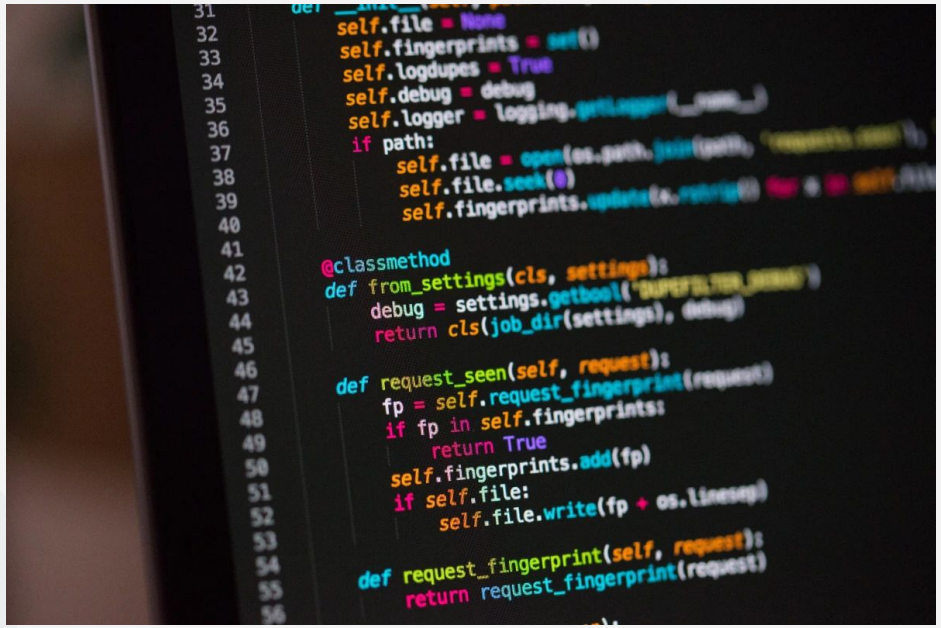

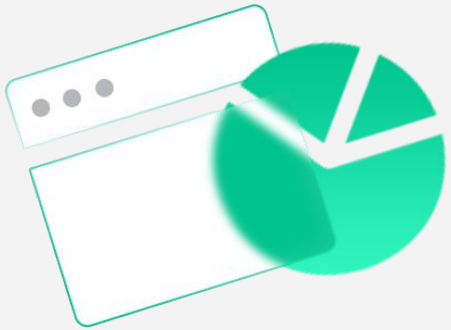

Terima Kasih